Análisis contrafactual en demografía y estudios de población

Ejemplos y ejercicios de clase

Dr. Jesús Daniel Zazueta Borboa

13 de Abril de 2026

Presentación

El objetivo de este documento es presentar dos ejemplos con sus respectivos ejercicios para poner en práctica lo aprendido, durante la clase de análisis contrafactual en demografía y estudios de población.

Preparar el ambiente de trabajo en R

Primero comenzamos limpiando el espacio de trabajo, declarando el directorio de trabajo, y cargando las librerias que vamos a utilizar.

```r
# Limpiar espacio de trabajo
rm(list = ls())

# Poner el directorio de trabajo, si se utiliza un .Rjproject no es necesario este paso
setwd("~/Desktop/Colmex/Ejercicio clase")

# Paqueterias que se van a utlizar
library(data.table) # Para aplicar funciones a una tabla de datos y obtener una nueva tabla de datos
library(tidyverse) # Para manipular base de datos
library(survey) # Para análisis de encuestas
library(readstata13) # Open stata files
```

Ejemplo 1: Cause-Deleted Life table

Este ejercicio contiene tasas de mortalidad y la proporción de diferentes causas de muerte por grupos de edad, sexo, año y entidad en México. La siguiente función, construye una tabla con causa eliminada.

Los datos son la publicación de Zazueta et al (2025). The impact of violence and COVID-19 on Mexico's life-expectancy losses and recent bounce-back, 2015–22, International Journal of Epidemology.

```r
CDLT <- function (nmx, age, Ri, Sex, nax = NULL, n){
    x <- age
    m <- length(x)

  if (is.null(nax)) {
    nax <- 0.5 * n

    if (n[2] == 4) {
      if (Sex == "MALES") {
        if (nmx[1] >= 0.107) {
          nax[1] <- 0.33
          nax[2] <- 1.352
```

```
      }
      else {
        nax[1] <- 0.045 + 2.684 * nmx[1]
        nax[2] <- 1.651 - 2.816 * nmx[1]
      }
    }
    if (Sex == "FEMALES") {
      if (nmx[1] >= 0.107) {
        nax[1] <- 0.35
        nax[2] <- 1.361
      }
      else {
        nax[1] <- 0.053 + 2.8 * nmx[1]
        nax[2] <- 1.522 - 1.518 * nmx[1]
      }
    }
  }
}

nqx <- (n * nmx)/(1 + (n - nax) * nmx)
nqx <- c(nqx[-(length(nqx))], 1)
for (i in 1:length(nqx)) {
  if (nqx[i] > 1)
    nqx[i] <- 1
}
npx <- 1 - nqx
l0 = 100000 #standard
lx <- round(cumprod(c(l0, npx)))
ndx <- -diff(lx)
lxpn <- lx[-1]
nLx <- n * lxpn + ndx * nax
Tx <- rev(cumsum(rev(nLx)))
lx <- lx[1:length(age)]
ex <- Tx/lx

nax[m] <- ex[m] #Último  nax es la esperanza de vida de esa edad

# Aquí comenzamos la CDLT
npix = npx^(1-Ri) # Obtener una probabilidad de sobrevivir sin causa i
nqix = 1 - npix # probabilidad de morir sin causa i
lix = lx/lx
lix = head(cumprod(c(100000, npix)), -1)
ndix <- lix * nqix
lxipn <- rep(0, length(x))
lxipn <- lix[-1]
lxipn[m] <- 0
naix <- n  + (1-Ri) * (nqx/nqix) * (nax-n)
for(i in 1:length(naix)){
  if(naix[i] == "-Inf")
    naix[i] <- 2.5
}
```

```r
  nLix <- n * lxipn + ndix * naix
  nLix[m] <- ndix[m]/nmx[m]*Ri[m] # We compute the last nLx
  Tix = rev(cumsum(rev(nLix)))
  eix = Tix/lix

  naix[m] <- eix[m] #Último nax es la esperanza de vida de esa edad

  lt <- data.frame(Age = age,
                   Sex,
                   n,
                   nmx = round(nmx, 4),
                   nqx = round(nqx, 4),
                   nax = round(nax, 4),
                   npx = round(npx,4),
                   lx, ndx,
                   Lx = round(nLx,3),
                   Tx = round(Tx,3),
                   ex = round(ex,3),
                   Ri = round(Ri,3),
                   lix, ndix,
                   naix = round(naix,3),
                   eix = round(eix,3)) # Son las columnas que solicitiamos nos regrese

  return(lt)
}
```

Abrimos la base de datos, la transformamos a formato long y después aplicamos la función de CDLT para estimar las tablas de vida sin causas i.

```r
Mex_forCDLT <- read.csv("Data_analysis_CDLT.csv", header = T, sep = ",")

#colnames(Mex_forCDLT) # si se quiere revisar el nombre de las columnas
#View(Mex_forCDLT) # si se quiere visualizar la base de datos


# Ponemos la base de datos en formato long, para hacer el cálculo por
# causa de muerte, y la declaramos como data table para facilitar el cálculo
# por año, sexo, causa de muerte y entidad federativa

Mex_for_CDLT_longer <- Mex_forCDLT %>%
  pivot_longer(!c(YEAR, SEX, Age_group, ENTIDAD_NAME, ENTIDAD,
                  PSY, Dx, mx),
               names_to = "CoD",
               values_to = "Prop") %>%
  arrange(ENTIDAD_NAME, ENTIDAD,YEAR, SEX, Age_group) %>%
  data.table()


# -- Calculamos la tabla de vida y CDLT para cada entidad, sexo y año
Life_table_Mex <- Mex_for_CDLT_longer[,cbind(CDLT(nmx = mx,
                                                  age = Age_group,
                                                  Sex = SEX,
                                                  Ri = Prop,
                                                  nax = NULL,
```

```r
                                                    n= c(1,4,rep(5,19)))),
                                  by=list(YEAR,SEX, CoD, ENTIDAD, ENTIDAD_NAME)]

# Se recomienda visualizar el output para ver que todo ok
#View(Life_table_Mex)
```

Ahora que tenemos las esperanzas de vida con y sin diferentes causas de muerte podemos crear escenarios contrafactuales y estimar la contribución de diferentes causas de muerte

```r
# Seleccionamos las esperanzas de vida a la edad 0, la observada y
# la e0 sin causa i
cfc_e0 <- Life_table_Mex %>%
  filter(Age==0) %>%
  dplyr::select(YEAR,SEX, CoD, ENTIDAD, ENTIDAD_NAME,
                ex, eix)

# Utilizaremos el ejemplo de Cardiovascular a nivel nacional,
cfc_e0_CVD <- cfc_e0 %>%
  filter(CoD=="circulatory" & ENTIDAD==0)

# Estimaremos la contribución de Cardiovascular al cambio en el sex gap in e0
cfc_sexgap_e0_CVD <- cfc_e0_CVD %>%
  pivot_wider(names_from = SEX,
              values_from = c(ex,eix)) %>%
  mutate(Sexgap_obs = ex_FEMALES - ex_MALES, # Sex gap observado
         Sexgap_cfc = eix_FEMALES - eix_MALES)

Viz_cfc <- ggplot(cfc_sexgap_e0_CVD) +
  geom_line(aes(x=YEAR, y =Sexgap_obs), linetype = "solid", color ="black") +
  geom_line(aes(x=YEAR, y =Sexgap_cfc), linetype = "dashed", color ="indianred4") +
  scale_x_continuous(breaks = c(2015,2019,2020,2021,2022)) +
  theme_grey() +
    theme(text = element_text(size = 14),
        legend.position = "",
        #legend.position=c(.10, 0.50),
        legend.background = element_rect(fill="transparent",
                                         size=1, linetype="solid", color = "white"),
        #strip.background = element_rect(color="black", fill="grey80", size=0.5, linetype="solid"),
        strip.background = element_rect(fill = "grey40", color = "grey20", size = 1),
        strip.text = element_text(colour = "white"),
        axis.text.x = element_text(angle = 0, vjust = 1, hjust=.5),
        legend.key.size = unit(.6, "cm"),
        legend.key.width = unit(.6,"cm"),
        legend.title = element_text(color = "Black", size = 12),
        legend.text = element_text(color = "Black", size = 12)) +
  labs(x="",
       y = "Sex gap in e0 (en años)")
Viz_cfc
```

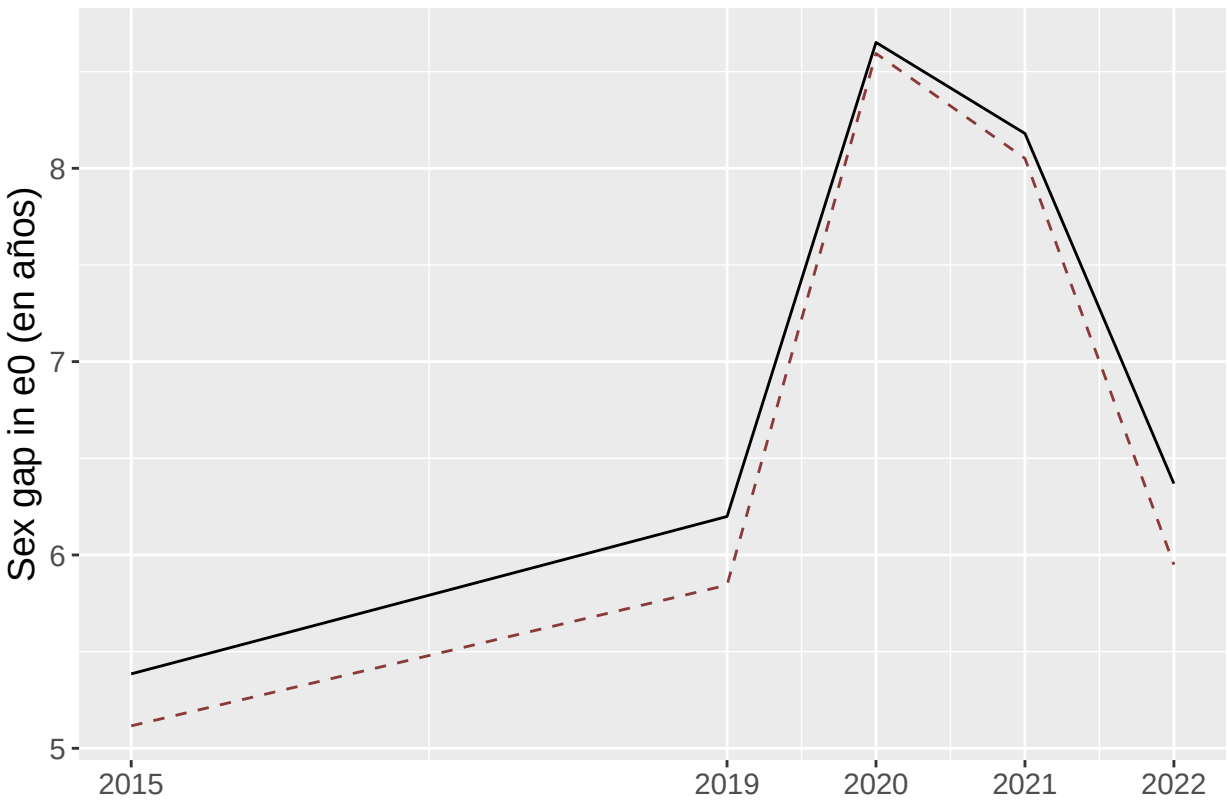

Después de visualizar como seria la tendencia del sex gap en e0 con y sin enfermedades cardiovasculares, podememos estimar la contribución que CVD tuvo a los niveles y a los cambios en el sexgap en e0 entre 2015 y 2022.

```
# Contribución a los niveles del sexgap en cada año
Contribution_sexgap_e0_CVD <- cfc_sexgap_e0_CVD %>%
  mutate(Contribution_Abs = Sexgap_obs - Sexgap_cfc,# Contribución absoluta de CVD
         Contribution_rela  = round(Contribution_Abs/Sexgap_obs*100,2)) %>%
    dplyr::select(ENTIDAD, ENTIDAD_NAME, YEAR,
                  Sexgap_obs, Sexgap_cfc,
                  Contribution_Abs, Contribution_rela)

Contribution_sexgap_e0_CVD$Contribution_rela[Contribution_sexgap_e0_CVD$YEAR==2015 |
                                             Contribution_sexgap_e0_CVD$YEAR==2022 ]
```

```
## [1] 5.00 6.58
```

```
# CVD contribuyo al sex gap en e0 5.23% en 2015 y 6.72% en 2022

# Contribución a los cambios del sexgap en e0 entre 2015 y 2022
Contribution_tochagessexgap_e0_CVD  <- Contribution_sexgap_e0_CVD %>%
  filter(YEAR==2015 | YEAR==2022) %>%
  dplyr::select(ENTIDAD, ENTIDAD_NAME, YEAR, Sexgap_obs, Sexgap_cfc) %>%
  pivot_wider(names_from = YEAR,
              values_from = c(Sexgap_obs, Sexgap_cfc)) %>%
  mutate(Change_obs = Sexgap_obs_2022 - Sexgap_obs_2015,
         Change_cfc = Sexgap_cfc_2022 - Sexgap_cfc_2015,
         Contribution_tochage_Abs = Change_obs - Change_cfc,# Contribución absoluta de CVD
         Contribution_tochage_rela  = round(Contribution_tochage_Abs/Change_obs*100,2)) %>%
  dplyr::select(ENTIDAD, ENTIDAD_NAME,
```

```
                Change_obs, Change_cfc,
                Contribution_tochage_Abs, Contribution_tochage_rela)

Contribution_tochagessexgap_e0_CVD$Contribution_tochage_rela
```

```
## [1] 15.24
```

```
# CVD contribuyo en un 14% al cambio en el sex gap en e0 entre 2015 y 2022
```

Ejemplo 2: Regresión logistica

Utilizaremos los datos de Zazueta et al (2024). En ese artículo los investigadores buscaron analizar la contribución que tienen las condiciones adversas durante la infancia y el peso corporal en edades adultas sobre la probabilidad de reportar diabetes para las diferentes cohortes de nacimiento.

La base de datos contiene información sobre diabetes, características sociodemográficas para tres cohortes de adultos mayores que se encuentran en las edades de 60 a 69 años.

```
Data_ENASEM  <- read.dta13("ENASEM_final_clase.dta")

# Modelo logisticio
Pooled_model <- glm(diabetes_final ~ Sexo + Edad + rural + factor(escolaridad) +
                      factor(B10_Excusado_dico) + factor(obesity_50) + nohealth +
                      factor(cohorte_final) +  factor(obesity_50) *factor(cohorte_final) +
                      factor(B10_Excusado_dico) *factor(cohorte_final),
                    data = Data_ENASEM, family = binomial())

#summary(Pooled_model)

# Creamos diferente bases de datos a las cuales les aplicaremos el model:

# Base de datos con las caracteristicas obeservadas,
Data_obs <- Data_ENASEM %>%
  dplyr::select(ID, diabetes_final, Sexo, Edad, rural, escolaridad,
                      B10_Excusado_dico, obesity_50, nohealth,
                      cohorte_final)

# Base de datos donde todas las personas tienen peso normal
Data_no_obesity <- Data_ENASEM %>%
  dplyr::select(ID, diabetes_final, Sexo, Edad, rural, escolaridad,
                      B10_Excusado_dico, obesity_50, nohealth,
                      cohorte_final) %>%
  mutate(obesity_50 = 0)

# Base de datos donde todas las personas no experimentaron condición adversa en la infancia
Data_no_EDDC <- Data_ENASEM %>%
  dplyr::select(ID, diabetes_final, Sexo, Edad, rural, escolaridad,
                      B10_Excusado_dico, obesity_50, nohealth,
                      cohorte_final) %>%
  mutate(B10_Excusado_dico = 0)

# Base de datos donde todas las personas no experimentaron condición adversa en la infancia y todos
# con paseo normal
Data_no_both <- Data_ENASEM %>%
  dplyr::select(ID, diabetes_final, Sexo, Edad, rural, escolaridad,
```

```r
                      B10_Excusado_dico, obesity_50, nohealth,
                      cohorte_final) %>%
  mutate(obesity_50 = 0,
         B10_Excusado_dico = 0)


# Estimar probabilidades a partir del modelo
Data_obs$PP_pooledmodel <- predict(Pooled_model,Data_obs, type = "response", na.rm=T)
Data_no_obesity$PP_pooledmodel <- predict(Pooled_model,Data_no_obesity, type = "response", na.rm=T)
Data_no_EDDC$PP_pooledmodel <- predict(Pooled_model,Data_no_EDDC, type = "response", na.rm=T)
Data_no_both$PP_pooledmodel <- predict(Pooled_model,Data_no_both, type = "response", na.rm=T)

# Creamos objetos que contiene las PP y sus errores estandar
predobs <- predict(Pooled_model, newdata = Data_obs, type = "link", se.fit = TRUE)
predno_obesity <- predict(Pooled_model, newdata = Data_no_obesity, type = "link", se.fit = TRUE)
predno_EDDC <- predict(Pooled_model, newdata = Data_no_EDDC, type = "link", se.fit = TRUE)
predno_both <- predict(Pooled_model, newdata = Data_no_both, type = "link", se.fit = TRUE)


# --- Estimamos las probabilidades y sus intervalos de confianza

# - Datos con la distribución original
Data_obs$PP_mean <- plogis(predobs$fit)
Data_obs$PP_lw <- plogis(predobs$fit - 1.96 * predobs$se.fit)
Data_obs$PP_up <- plogis(predobs$fit + 1.96 * predobs$se.fit)

# - Datos con la distribución todo peso normal
Data_no_obesity$PP_mean <- plogis(predno_obesity$fit)
Data_no_obesity$PP_lw <- plogis(predno_obesity$fit - 1.96 * predobs$se.fit)
Data_no_obesity$PP_up <- plogis(predno_obesity$fit + 1.96 * predno_obesity$se.fit)


# - Datos con la distribución de no condición adversa en la infancia
Data_no_EDDC$PP_mean <- plogis(predno_EDDC$fit)
Data_no_EDDC$PP_lw <- plogis(predno_EDDC$fit - 1.96 * predno_EDDC$se.fit)
Data_no_EDDC$PP_up <- plogis(predno_EDDC$fit + 1.96 * predno_EDDC$se.fit)


# - Datos con la distribución de peso normal y no condicion adversa en la ifnancia
Data_no_both$PP_mean <- plogis(predno_both$fit)
Data_no_both$PP_lw <- plogis(predno_both$fit - 1.96 * predno_both$se.fit)
Data_no_both$PP_up <- plogis(predno_both$fit + 1.96 * predno_both$se.fit)


# Estimamos las probabilidades de tener diabetes

PP_diabetes_obs <- Data_obs %>%
  group_by(cohorte_final) %>%
  summarize(PP_mean = mean(PP_mean, na.rm=T),
            PP_lw = mean(PP_lw, na.rm=T),
            PP_up = mean(PP_up, na.rm=T)) %>%
  mutate(escenario = 1)
```

```r
PP_diabetes_noECCD <- Data_no_EDDC %>%
  group_by(cohorte_final) %>%
  summarize(PP_mean = mean(PP_mean, na.rm=T),
            PP_lw = mean(PP_lw, na.rm=T),
            PP_up = mean(PP_up, na.rm=T))  %>%
  mutate(escenario = 2)

PP_diabetes_noobesity<- Data_no_obesity %>%
  group_by(cohorte_final) %>%
  summarize(PP_mean = mean(PP_mean, na.rm=T),
            PP_lw = mean(PP_lw, na.rm=T),
            PP_up = mean(PP_up, na.rm=T))  %>%
  mutate(escenario = 3)

PP_diabetes_noboth <- Data_no_both %>%
  group_by(cohorte_final) %>%
  summarize(PP_mean = mean(PP_mean, na.rm=T),
            PP_lw = mean(PP_lw, na.rm=T),
            PP_up = mean(PP_up, na.rm=T))  %>%
  mutate(escenario = 4)

# Combinamos bases de datos
Base_final <- rbind(PP_diabetes_obs,
                    PP_diabetes_noobesity,
                    PP_diabetes_noECCD,
                    PP_diabetes_noboth)

# Eriquetar variables
Base_final$cohorte_final <- factor(Base_final$cohorte_final,
                                   levels = c(0,1,2),
                                   labels = c("1930-39", "1940-49", "1950-59"))

Base_final$escenario <- factor(Base_final$escenario,
                               levels = c(1,2,3,4),
                               labels = c("Observado",
                                          "No EDDC",
                                          "No obesity",
                                          "No EDDC & No Obesity"))


Grafica <- ggplot(Base_final,mapping = aes(x=escenario,
                                           y=PP_mean,
                                           group=escenario,
                                           fill=escenario)) +
  geom_bar(position = "dodge", stat = "identity") +
  geom_errorbar(aes(ymin = PP_lw, ymax = PP_up),
                width = 0.2, position = position_dodge(0.9)) +
  facet_grid(.~cohorte_final) +
  theme_dark()+
  scale_color_manual(values = c(rep("black",4))) +
  scale_fill_manual(values = c("#252525","#636363","#969696","#BDBDBD")) +
  theme(text = element_text(size = 22),
        legend.position = "",
```

```
        #legend.position=c(.10, 0.50),
        legend.background = element_rect(fill="transparent",
                                         size=1, linetype="solid", color = "white"),
        #strip.background = element_rect(color="black", fill="grey80", size=0.5, linetype="solid"),
        strip.background = element_rect(fill = "grey40", color = "grey20", size = 1),
        strip.text = element_text(colour = "white"),
        axis.text.x = element_text(angle = 60, vjust = 1, hjust=1),
        legend.key.size = unit(.6, "cm"),
        legend.key.width = unit(.6,"cm"),
        legend.title = element_text(color = "Black", size = 20),
        legend.text = element_text(color = "Black", size = 20)) +
  #guides(fill=guide_legend(ncol=2)) +
  labs(#title = "",
       y="Probabilidad de reportar diabetes",
       x="")
Grafica
```

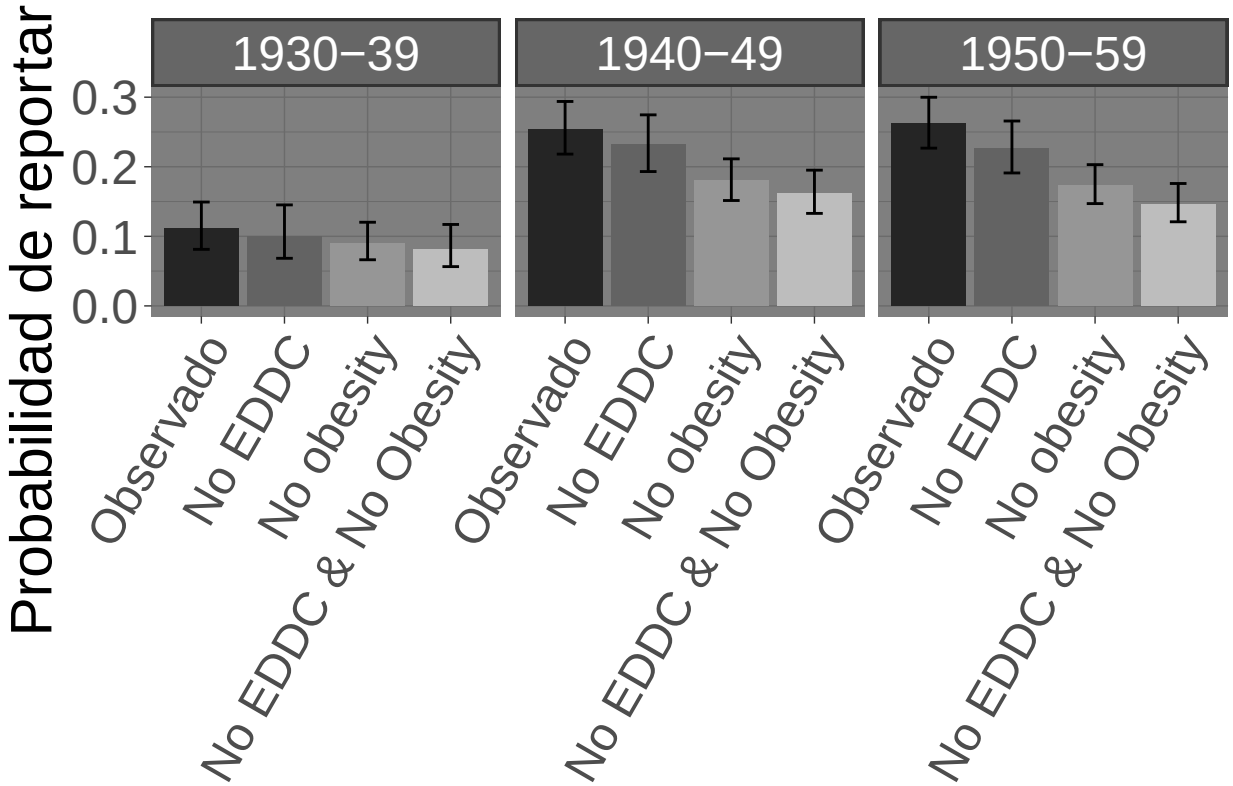

Por lo tanto, las contribuciones de eliminar cada condición sobre la probabilidad de reportar diabetes se pueden estimar a partir de las diferencias entre la probabilidad observada y la probabilidad estimada a partir de hacer un cambio en la distribución.

Ejercicios para el estudiante

1) Usando CDLT, cuál sería el impacto que tendría la eliminación de mortalidad por mortalidad externa en la esperanza de vida a lo largo del tiempo para cada entidad federativa

2) Para el análisis de regresión: 2.1 Que pasaría si se hiciera un cambio en la distribución educativa, donde todas las personas tengan el nivel de escolaridad más alto 2.2 Estima la contribución absoluta y relativa de eliminar EDDC y obesidad en las cohortes analizadas

Referencia

Zazueta-Borboa, J.D., Rafael Samper-Ternent, Rebeca Wong, Neil Mehta, Economic Disadvantage During Childhood, Obesity, and Diabetes Across Three Birth Cohorts of Older Mexicans, The Journals of Gerontology: Series B, Volume 79, Issue 12, December 2024, gbae178, https://doi.org/10.1093/geronb/gbae178

Zazueta-Borboa, J.D. Paola Vázquez-Castillo, Maria Gargiulo, José Manuel Aburto, The impact of violence and COVID-19 on Mexico's life-expectancy losses and recent bounce-back, 2015–22, International Journal of Epidemiology, Volume 54, Issue 3, June 2025, dyaf034, https://doi.org/10.1093/ije/dyaf034